

제4장 ARMA모형의 식별 및 추정

4.2 시계열 모형의 추정

- 적률법(Method of Moments)
- 보통선형최소제곱법(Ordinary Least Squares Method)
- 비선형최소제곱법(Nonlinear Least Squares Method)
- 최대우도법(Maximum Likelihood Method) ◀

4.2.1 정확한 우도함수

※ 시계열 데이터: 인근 시점값들이 독립이 아니기 때문에 정확한 우도함수의 표현이 어려울 수 있다.

- 시계열 데이터가 AR(1)모형을 따르는 경우

$$Z_t = \phi Z_{t-1} + a_t, \quad a_t \sim N(0, \sigma_a^2)$$

- 데이터 ($Z_1 = z_1, Z_2 = z_2$)가 관측되었다면, 결합확률밀도함수는

$$f_{Z_1, Z_2}(z_1, z_2; \phi, \sigma_a^2) = f_{Z_1}(z_1; \phi, \sigma_a^2) f_{Z_2|Z_1}(z_2|z_1; \phi, \sigma_a^2)$$

여기서, $Z_2|Z_1 = z_1 \sim N(\phi z_1, \sigma_a^2) \rightarrow f_{Z_2|Z_1}(z_2|z_1; \phi, \sigma_a^2) = \frac{1}{\sqrt{2\pi} \sigma_a} \exp\left[-\frac{(z_2 - \phi z_1)^2}{2\sigma_a^2}\right]$

- (z_1, z_2, \dots, z_n)이 관측되는 경우, AR(1)모형의 우도함수는

$$f_{Z_1, \dots, Z_n}(z_1, \dots, z_n; \phi, \sigma_a^2) = f_{Z_1}(z_1; \phi, \sigma_a^2) \prod_{t=2}^n f_{Z_t|Z_{t-1}}(z_t|z_{t-1}; \phi, \sigma_a^2)$$

여기서, $f_{Z_t|Z_{t-1}}(z_t|z_{t-1}; \phi, \sigma_a^2) = \frac{1}{\sqrt{2\pi} \sigma_a} \exp\left[-\frac{(z_t - \phi z_{t-1})^2}{2\sigma_a^2}\right], t = 2, \dots, n$

- Z_1 의 분포가 별도로 필요한데, 통상 수렴된 후의 분포를 사용한다.

$$Z_1 \sim N\left(0, \frac{\sigma_a^2}{(1-\phi^2)}\right)$$

※ 통상적으로 우도함수는 로그변환을 취하는 로그우도함수를 고려하여 최적화한다.

• AR(1)모형의 로그우도함수

$$\begin{aligned}\log \mathcal{L}(\phi, \sigma_a^2; z_1, \dots, z_n) &= \log f_{Z_1}(z_1; \phi, \sigma_a^2) + \sum_{t=2}^n \log f_{Z_t|Z_{t-1}}(z_t|z_{t-1}; \phi, \sigma_a^2) \\ &= -\frac{n}{2} \log(2\pi) + \frac{1}{2} \log(1-\phi^2) - \frac{n}{2} \log \sigma_a^2 - \frac{S(\phi)}{2\sigma_a^2}\end{aligned}$$

$$\text{여기서, } S(\phi) = z_1^2(1-\phi^2) + \sum_{t=2}^n (z_t - \phi z_{t-1})^2$$

4.2.2 조건있는 우도함수(Conditional Likelihood Function)

※ 시계열 데이터 Z_t 들은 서로 독립이 아니기 때문에 이를 바탕으로 결합확률밀도함수를 유도하고 우도함수를 산출하기 어렵다. 대신 오차항인 a_t 들은 서로 독립이므로 이를 바탕으로 우도함수를 구성하고자 한다.

■ 오차항 $a_t(t = 1, 2, \dots, n)$ 들이 관측된다고 하면 결합확률밀도함수는

$$f_{a_1, \dots, a_n}(a_1, \dots, a_n; \Theta) = (2\pi\sigma_a^2)^{-\frac{n}{2}} \exp \left[-\frac{1}{2\sigma_a^2} \sum_{t=1}^n a_t^2 \right]$$

■ ARMA(p,q)모형

$$a_t = \theta_1 a_{t-1} + \dots + \theta_q a_{t-q} + Z_t - \phi_1 Z_{t-1} - \dots - \phi_p Z_{t-p}$$

• 오차항을 산출하려면 아래 초기값이 필요하다.

$$a_* = (a_{1-q}, \dots, a_{-1}, a_0)$$

$$z_* = (z_{1-p}, \dots, z_{-1}, z_0)$$

$$\blacktriangleright z_1 \text{ 관측} \rightarrow a_1 = \theta_1 a_0 + \dots + \theta_q a_{1-q} + z_1 - \phi_1 z_0 - \dots - \phi_p z_{1-p}$$

$$\blacktriangleright z_2 \text{ 관측} \rightarrow a_2 = \theta_1 a_1 + \dots + \theta_q a_{2-q} + z_2 - \phi_1 z_1 - \dots - \phi_p z_{2-p} \quad \blacktriangleright \dots$$

• 위의 초기조건 하에서의 로그우도함수는

$$\log \mathcal{L}_*(\phi, \sigma_a^2; z_1, \dots, z_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_a^2 - \frac{S_*(\Theta)}{2\sigma_a^2}$$

$$\text{여기서, } S_*(\Theta) = \sum_{t=1}^n a_t^2(\Theta | z_*, a_*, z_1, \dots, z_n)$$

\Rightarrow 로그우도함수 최대화 = $S_*(\Theta)$ 최소화

■ 초기값에 대한 가정

① 과거 오차항을 모두 0으로 둔다: $a_{1-q} = \dots = a_0 = 0$

② 과거 시계열 값을 모두 표본평균으로 대체한다: $z_{1-p} = \dots = z_0 = \bar{z}$

4.2.3 조건없는 우도함수(Unconditional Likelihood Function)

■ 오차항들을 산출하기 위해, 과거값들을 예측하여 우도함수를 산출하는 방법

· 후방예측(back forecasting): 과거값을 예측하는 것

[예] ARMA(p,q)모형을 후방형태로 표현하면

$$Z_t - \phi_1 Z_{t+1} - \dots - \phi_p Z_{t+p} = b_t - \theta_1 b_{t+1} - \dots - \theta_q b_{t+q}$$

또는

$$Z_t = \phi_1 Z_{t+1} + \dots + \phi_p Z_{t+p} + b_t - \theta_1 b_{t+1} - \dots - \theta_q b_{t+q}$$

■ 조건없는 우도함수(Box et al., 1994)

$$\log \mathcal{L}(\phi, \sigma_a^2; z_1, \dots, z_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma_a^2 - \frac{S(\theta)}{2\sigma_a^2}$$

$$\text{여기서, } S(\theta) = \sum_{t=-M}^n E^2[a_t | \theta, z_1, \dots, z_n]$$

★ M : 과거 시계열 후방예측값의 변화가 매우 작아지는(예컨대 0.005 이하) 충분히 큰 수

[예 4.6]

4.3 잔차검정

■ 시계열모형: 오차항이 백색잡음이라고 가정

→ ‘잔차’를 구하여 이를 검정

■ ARMA(p,q)모형 $\Phi_p(B)Z_t = \Theta_q(B)a_t$ 에서의 잔차: $\hat{a}_t = \hat{\Theta}_q^{-1}(B)\hat{\Phi}_p(B)Z_t$

→ 실제잔차: $\hat{a}_t = z_t - (t\text{시점 예측값})$

- 잔차가 정규분포를 따르는지 여부: 정규확률도표
- 등분산성 및 패턴 유무 확인: 잔차 산점도
- 잔차 시계열이 백색잡음을 따르는지 여부
- ACF와 PACF를 구해서 확인
- 포트맨토(portmanteau) 검정

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_K = 0$$

· 시차 k 의 표본자기상관계수: $r_k = \frac{\sum_{t=k+1}^n \hat{a}_t \hat{a}_{t-k}}{\sum_{t=k+1}^n \hat{a}_t^2}, k = 1, 2, \dots, K$

- 검정통계량

① Box and Pierce(1970) : $Q = n \sum_{k=1}^K r_k^2 \sim \chi^2(K-p-q)$

② Ljung and Box(1978): $Q = n(n+2) \sum_{k=1}^K \frac{r_k^2}{n-k} \sim \chi^2(K-p-q)$

[예] 나일강 유량 시계열 데이터에 대한 LB 검정 결과

시차	12	24	36	48
카이제곱	11.9	16.6	25.0	37.3
자유도	9	21	33	45
p-값	0.222	0.735	0.841	0.787